Sprawozdanie ESI

Wydział Zarządzania AGH

Filip Kasprzycki
Bartłomiej Klajn
Daniel Kłodowski
Michał Król

Część 1: Sztuczne Sieci Neuronowe

1. Opis podjętych do rozwiązania problemów:

W ramach projektu wykorzystaliśmy zbiór danych “Credit Risk Dataset” opisujący profil finansowy klientów starających się o kredyt.

- **Problem regresyjny** - na podstawie podanych zmiennych objaśniających sieć ma nauczyć się przewidywać wysokość oprocentowania kredytu (loan_int_rate).

- **Problem klasyfikacyjny** - na podstawie określonych zmiennych sieć ma za zadanie przewidywać zmienną zero-jedynkową (loan_status). Wynik informuje nas, czy dany klient spłacił kredyt - wartość 0, czy nie - wartość 1.

2. Analiza wpływu parametrów na skuteczność działania sieci:

Badania przeprowadziliśmy oddzielnie dla problemu regresji oraz klasyfikacji. Zgodnie z założeniami projektu przetestowano 8 różnych parametrów. Żeby, wyniki były miarodajne i uwzględniały niedeterministyczny charakter procesu uczenia, dla każdego wariantu wykonaliśmy po 5 iteracji z różnymi wartościami ziarna losowości (wagi początkowej).

Testowane parametry:

- Learning rate - współczynnik uczenia
- Activation – funkcja aktywacji
- Epochs – liczba epok
- Division Coefficient – proporcje podziału danych na zbiór uczący i testowy
- Layers - liczba warstw i neuronów w każdej z nich
- Multiplier - mnożnik do przeskalowania wag inicjalizujących trenowaną sieć
- Min change – minimalna wymagana zmiana błędu, by zatrzymać uczenie sieci
- Target Loss – docelowy błąd uczenia.

W przypadku sieci regresyjnej miarą błędu jest MSE – Mean Squared Error - średni błąd kwadratowy. Dla sieci klasyfikacyjnej – BCE - Binary Cross-Entropy.

BCE = −(y · log(y_s) + (1 − y) · log(1 − y_s))

Y - wartość rzeczywista (zmienna zero-jedynkowa)

Y_s - wartość szacowana (prawdopodobieństwo)

Analiza problemu regresyjnej sieci neuronowej

Tabela 1. Zestawienie wyników sieci dla problemu regresji (przewidywanie oprocentowania).

Badany Parametr	Wartość	Średni czas uczenia sieci [s]	Błąd MSE dla testowego zbioru
1. Learning Rate	0.1	13,15	1,75
	0.01	15,24	1,76
	0.001	15,49	4,36
	0.0001	31,91	66,90
2. Activation	leaky_relu	6,91	2,81
	relu	6,18	2,86
	sigmoid	15,12	4,36
	tanh	11,32	3,90
3. Epochs	100	3,09	66,84
	500	16,13	7,59
	1000	33,67	4,36
	2000	59,63	2,83
4. Division Coeff.	0.6	11,90	4,44
	0.7	14,53	4,42
	0.8	17,06	4,36
	0.9	18,33	4,26
5. Layers	[21, 21, 1]	27,23	4,58
	[21, 24, 1]	30,63	4,69
	[21, 5, 1]	5,84	5,13
	[21, 21, 4, 1]	31,08	9,53
6. Multiplier	0.0001	38,04	4,35
	0.001	35,07	4,35
	0.01	32,72	4,36
	0.1	31,54	4,89

7. Min Change	0.01	8,95	6,43
	0.0001	15,18	4,36
	0,000001	15,94	4,36
	0,00000001	17,27	4,36
8. Target Loss	0.1	31,22	4,36
	0.01	19,29	4,36
	0.001	30,13	4,36
	0.0001	17,87	4,36

Wnioski z analizy regresji:

Współczynnik uczenia - Learning Rate

W problemie regresji najwyższą skuteczność uzyskano dla wartości 0.1 (błąd MSE: 1.74). Zauważono, że w przeciwieństwie do klasyfikacji, dla problemu regresji wyższy współczynnik uczenia okazał się kluczowy. Zastosowanie bardzo małego kroku (0.0001) spowodowało drastyczny wzrost błędu do poziomu 66.90, co sugeruje, że sieć przy tak niskim parametrze nie była w stanie wyjść z lokalnych minimów funkcji celu.

Sieć [21, 5, 1] była nie tylko celniejsza, ale też najszybsza (czas ok. 5.8s), co czyni ją najbardziej efektywnym wyborem.

Funkcje aktywacji – Activation

Najlepsze rezultaty (najniższy błąd i krótki czas pracy) przyniosły funkcje ReLU oraz Leaky ReLU. Funkcje typu Sigmoid i Tanh, mimo że są popularne, w tym konkretnym zadaniu regresyjnym wydłużyły czas uczenia i dały gorsze wyniki (MSE powyżej 3.9), co potwierdza ich tendencję do nasycania się przy przewidywaniu wartości ciągłych.

Liczba epok – Epochs

Wykres błędu w funkcji epok pokazuje klasyczną zależność: im więcej iteracji, tym błąd jest mniejszy. Przy 100 epokach sieć była skrajnie niedouczona (błąd 66.84), natomiast przy 2000 epokach błąd spadł do poziomu 2.82. Widać jednak, że od 1000 epok spadek błędu wyhamowuje, co sugeruje, że dalsze zwiększanie tego parametru mogłoby prowadzić do nadmiernego dopasowania (overfittingu).

Architektura sieci – Layers

Podobnie jak w klasyfikacji, tutaj również wygrała prostota. Najlepszy balans między czasem a błędem uzyskała sieć o strukturze [21, 5, 1]. Próba zastosowania sieci

głębokiej o 4 warstwach ukrytych [21, 21, 4, 1] skończyła się fatalnym wynikiem (błąd 9.53), co udowadnia, że przy tej skali danych dodawanie kolejnych warstw jedynie utrudnia proces optymalizacji wag.

Parametry zatrzymania - Min Change / Target Loss

Analiza wykazała, że większość testów zatrzymywała się na podobnym poziomie błędu (4.36). Oznacza to, że sieć dość szybko osiąga stabilizację i ekstremalne zwiększanie precyzji (np. Min Change do 0.00000001) nie przekłada się na realną poprawę wyników, a jedynie nieznacznie wydłuża czas obliczeń.

Analiza klasyfikacyjnej sieci neuronowej

Tabela 2. Zestawienie parametrów sieci dla problemu klasyfikacji (status kredytu).

Badany Parametr	Wartość	Czas uczenia [s] (Ucząca)	Błąd BCE (Zbiór testowy)
1. Learning Rate	0.1	0,07	13,78
	0.01	0,18	6,29
	0.001	27,51	0,42
	0.0001	33,67	0,28
2. Activation	leaky_relu	7,32	
	relu	14,55	1,89
	sigmoid	27,94	0,42
	tanh	26,72	0,56
3. Epochs	100	3,15	0,70
	500	15,89	0,45
	1000	32,96	0,42
	2000	53,50	0,36
4. Division Coeff.	0.6	23,42	0,35
	0.7	30,79	0,34
	0.8	33,13	0,42
	0.9	41,80	0,39

5. Layers	[21, 5, 1]	14,75	0,35
	[21, 21, 1]	54,57	0,40
	[21, 24, 1]	43,46	0,42
	[21, 21, 4, 1]	67,31	1,79
6. Multiplier	0.1	32,81	0,37
	0.01	36,66	0,42
	0.001	34,95	0,39
	0.0001	30,13	0,36
7. Min Change	0.01	1,15	0,54
	0.0001	24,13	0,47
	0,000001	17,17	0,42
	0,00000001	18,88	0,42
8. Target Loss	0.1	20,78	0,42
	0.01	19,97	0,42
	0.001	21,77	0,42
	0.0001	22,94	0,42

Wnioski z analizy klasyfikacji:

Współczynnik uczenia - Learning Rate To kluczowy parametr dla stabilności modelu. Przy wartości 0.1 sieć wykazała brak zbieżności przy błędzie BCE wynoszącym aż 13,77, co oznacza, że zbyt duży krok uniemożliwił naukę i poprawne dostosowanie wag. Najlepsze wyniki (0.28) uzyskano przy bardzo niskim współczynniku (0.0001), co pozwoliło sieci na precyzyjne wypracowanie reguł klasyfikacji, choć wymagało znacznie dłuższego czasu trenowania.

Architektura sieci - Layers Badanie wykazało, że dla tego problemu optymalne są proste struktury. Najniższy błąd (0.35) osiągnęła sieć z zaledwie 5 neuronami w warstwie ukrytej. Rozbudowa sieci do 4 warstw ukrytych nie tylko znacząco wydłużyła czas trenowania (o 178%), ale również wyraźnie pogorszyła wynik końcowy (błąd wzrósł do 1.78). Może to sugerować, że zbyt skomplikowany model zaczął doszukiwać się nieistniejących zależności w danych zamiast wychwytywać główne trendy.

Liczba epok - Epochs

Zaobserwowano, że sieć potrzebuje odpowiedniej liczby iteracji do stabilizacji wyników. O ile przy 100 epokach błąd był wysoki, o tyle przy 2000 epokach model osiągnął bardzo

dobre parametry. Dalsze zwiększanie liczby epok do 5000 jedynie wydłużało czas obliczeń i nie przyniosło już znaczącej poprawy skuteczności, co jest nieefektywne z punktu widzenia zasobów.

Podział danych - Division Coeff

Najlepszą zdolność do uogólniania wiedzy sieć zdobyła przy podziale 0.7 (70% danych do nauki). Zwiększenie zbioru uczącego do 90% nie poprawiło wyników testowych, co potwierdza, że zachowanie odpowiednio dużej próbki niezależnych danych testowych jest niezbędne do rzetelnej i dokładnej oceny rzeczywistej skuteczności modelu.

Część 2: Metody Machine learningowe

1. Metoda K najbliższych sąsiadów

Klasyczny algorytm K Najbliższych Sąsiadów ma za zadanie znaleźć k sąsiadów, do których klasyfikowane obiekty są najbliższe dla wybranej metryki (np. Euklidesa), a następnie określa wynik klasyfikacji na podstawie większości głosów tych najbliższych k sąsiadów, biorąc pod uwagę, która klasa jest reprezentowana największą liczbę razy w grupie k najbliższych sąsiadów. Bądź licząc średnią wartość w przypadku metody regresyjnej.

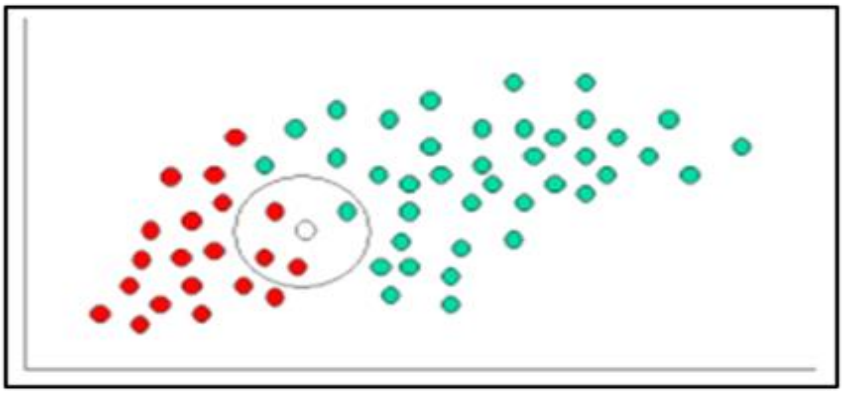

W naszym projekcie korzystamy z poniższych metryk:

- Manhattańska

  Nazwa pochodzi od układu ulic na Manhattanie. Odległość obliczana jest jako suma modułów różnic między współrzędnymi punktów – poruszamy się tylko wzdłuż osi układu współrzędnych (pod kątem prostym).

  wzór: $d(x, y) = \sum_{i=1}^{n} |x_i - y_i|$

- Czebyszewa

  Definiuje odległość jako maksymalną z różnic między współrzędnymi punktów w dowolnym wymiarze.

wzór: $d(x, y) = \max_i(|x_i - y_i|)$

- Minkowski

  Jest to uogólniona miara odległości, która stanowi matematyczną podstawę dla powyższych metryk. Wprowadza parametr p, który decyduje o charakterze obliczeń.

  wzór: $d(x, y) = \left(\sum_{i=1}^{n} |x_i - y_i|^p\right)^{1/p}$

- Euklidesowa

  Jest to najczęściej stosowana miara odległości, odpowiadająca fizycznej odległości między dwoma punktami w linii prostej (zgodnie z twierdzeniem Pitagorasa).

  $$d(x, y) = \sqrt{\sum_{i=1}^{n} (x_i - y_i)^2}$$

Różnice w zależności od tego czy metoda jest klasyfikacyjna czy regresyjna

W przypadku metody klasyfikacyjnej elementowi przewidywanemu przypisuje się klasę najbardziej liczną spośród k najbliższych sąsiadów, w przypadku metody regresyjnej istnieją dwa podejścia przypisujemy wartość średnią bądź medianę. W przypadku naszego projektu wykorzystujemy podejście ze średnią.

W przypadku naszego projektu sprawdzamy wydajność modelu w zależności od ilości sąsiadów których wartości bierzemy pod uwagę, a także w zależności od tego którą z metryk wykorzystamy.

2. Maszyna wektorów nośnych (SVM)

Działanie algorytmu SVM polega na przekształceniu danych do przestrzeni wielowymiarowej w taki sposób, aby możliwe było ich rozdzielenie za pomocą hiperpłaszczyzny. Algorytm wyznacza optymalną granicę decyzyjną maksymalizującą margines pomiędzy klasami. W przypadku danych nieliniowo separowanych stosowane są funkcje jądra, które umożliwiają odwzorowanie danych do przestrzeni o wyższym wymiarze, gdzie możliwe jest ich rozdzielenie. Do najważniejszych parametrów modelu należą: parametr regularyzacji C, który kontroluje poziom dopasowania modelu do danych, oraz rodzaj jądra.

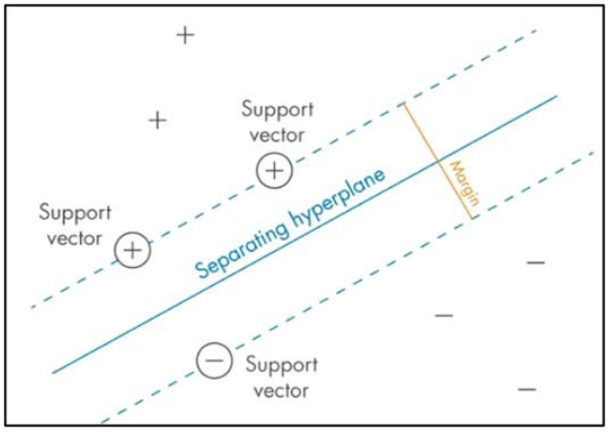

Wykorzystane parametry w pracy:

- **Parametr C** – kontroluje kompromis między złożonością modelu a jego zdolnością do prawidłowej klasyfikacji danych treningowych.

- **Rodzaj jądra (kernel)** – funkcja jądra umożliwia przekształcenie danych do przestrzeni o wyższym wymiarze, co pozwala na rozdzielenie danych nieliniowych. W analizie uwzględniono następujące rodzaje jąder:

  - linear czyli jądro liniowe
  - poly czyli jądro wielomianowe
  - rbf czyli jądro radialne
  - sigmoid czyli jądro sigmoidalne

Parametry C oraz kernel są wykorzystywane zarówno w modelach klasyfikacyjnych, jak i regresyjnych. W obu przypadkach odpowiadają one za kontrolę dopasowania modelu oraz sposób odwzorowania danych, jednak ich wpływ odnosi się odpowiednio do klasyfikacji lub przewidywania wartości liczbowych.

W modelu Klasyfikacyjnym:

- **C** kontroluje, jak bardzo model chce unikać błędów klasyfikacji.
- **kernel** decyduje, jak wygląda granica między klasami.

W modelu Regresyjnym:

- **C** kontroluje, jak bardzo model „karze” za duże błędy predykcji.
- **kernel** decyduje o kształcie funkcji regresji.

3. Drzewo decyzyjne

Drzewo decyzyjne jest metodą uczenia maszynowego, która polega na dzieleniu danych na coraz mniejsze podzbiory w celu przewidzenia klasy (w problemach klasyfikacyjnych) lub wartości (w problemach regresyjnych). Struktura modelu przypomina drzewo, które składa się z kilku podstawowych elementów. Na początku znajduje się węzeł korzenia, reprezentujący cały zbiór danych. Następnie dane są dzielone w kolejnych węzłach decyzyjnych, gdzie sprawdzane są warunki dotyczące cech. Poszczególne decyzje prowadzą do kolejnych części drzewa poprzez gałęzie, aż do osiągnięcia liści. Liście stanowią końcowy etap modelu i zawierają wynik predykcji, klasę w przypadku klasyfikacji lub wartość liczbową w przypadku regresji.

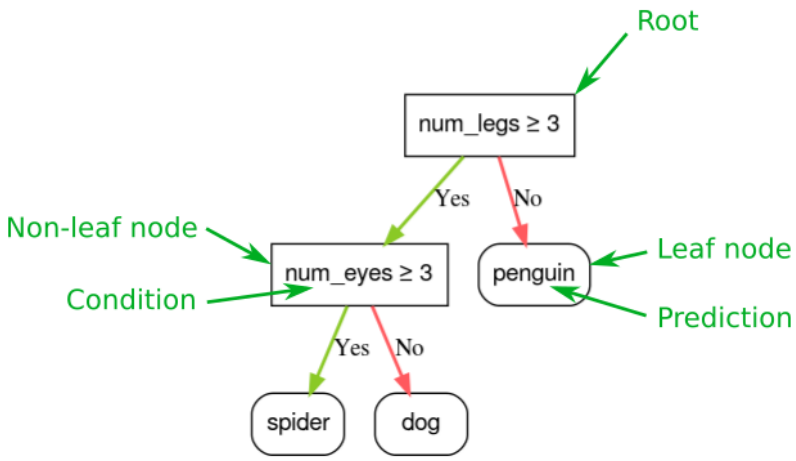

Wykorzystane parametry w pracy

Maksymalna głębokość drzewa (max_depth)

Parametr ten określa maksymalną liczbę poziomów drzewa decyzyjnego. Odpowiada on za złożoność modelu.

Minimalna liczba obserwacji w liściu (min_samples_leaf)

Parametr ten określa minimalną liczbę próbek, które muszą znajdować się w liściu drzewa

W modelu klasyfikacyjnym

max_depth określa, jak głęboko drzewo może się rozgałęziać, czyli ile kolejnych pytań model może zadać, zanim zdecyduje, do której klasy przypisać obserwację. Im większa głębokość, tym dokładniej drzewo dopasowuje się do danych uczących, ale

jednocześnie rośnie ryzyko, że zacznie „zapamiętywać" przypadki zamiast wyciągać ogólne wnioski.
min_samples_leaf to minimalna liczba obserwacji, jaka musi trafić do liścia drzewa. Jeśli ustawimy tę wartość na 1, drzewo może tworzyć liście zawierające pojedyncze obserwacje, co zwykle prowadzi do przeuczenia. Zwiększenie tej wartości wymusza, żeby model podejmował decyzje na podstawie większych grup podobnych przypadków, dzięki czemu działa stabilniej na nowych danych.

W modelu regresyjnym
max_depth wpływa na to, jak precyzyjnie drzewo potrafi odwzorować konkretne wartości liczbowe, w tym wypadku oprocentowanie kredytu. Głębsze drzewo potrafi dokładniej trafiać w wartości ze zbioru uczącego, ale kosztem gorszego działania na danych testowych

min_samples_leaf decyduje o tym, jak „gładka" jest funkcja zwracana przez model. Przy małej wartości model potrafi zwracać bardzo różne wartości dla bardzo podobnych obserwacji, prognozy stają się niestabilne. Większa wartość oznacza, że przewidywane oprocentowanie jest uśrednione z większej liczby przypadków, więc wyniki są bardziej przewidywalne i mniej wrażliwe na pojedyncze anomalie w danych.

4. Las losowy
Las losowy jest metodą, która polega na budowie wielu drzew decyzyjnych i łączeniu ich wyników w celu uzyskania lepszej jakości predykcji. Każde drzewo trenowane jest na losowej próbce danych oraz z wykorzystaniem losowego podzbioru cech, co zwiększa różnorodność modeli.
W przypadku klasyfikacji wynik końcowy uzyskiwany jest poprzez głosowanie większościowe, natomiast w regresji jako średnia z przewidywań wszystkich drzew.

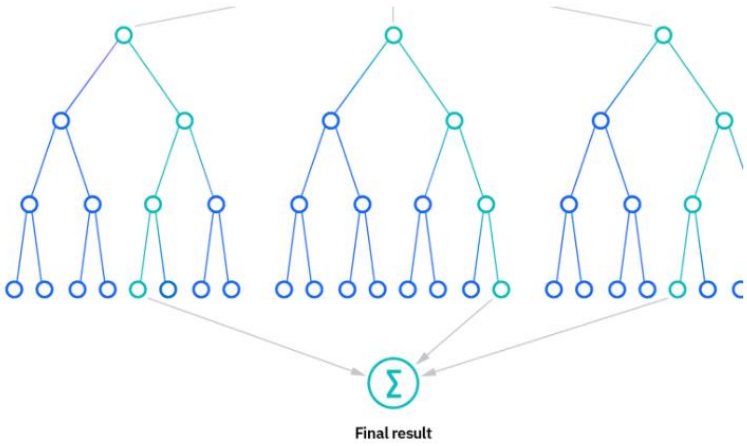

Wykorzystane parametry w pracy

Liczba drzew (n_estimators)

Określa, ile pojedynczych drzew decyzyjnych zostanie zbudowanych w ramach lasu losowego. Każde z drzew uczy się na nieco innym fragmencie danych i zwraca własną predykcję, a końcowy wynik modelu jest agregacją wszystkich tych głosów poprzez głosowanie większościowe w klasyfikacji albo uśrednianie w regresji.

Maksymalna głębokość drzew(max_depth)

Określa, jak rozbudowane może być pojedyncze drzewo wchodzące w skład lasu, czyli ile kolejnych pytań kontrolnych może ono zadać, zanim podejmie decyzję.

W modelu klasyfikacyjnym

n_estimators odpowiada za stabilność i wiarygodność decyzji klasyfikacyjnych - im więcej drzew głosuje nad tym, czy dany kredyt zostanie spłacony, tym mniejsze prawdopodobieństwo, że model pomyli się z powodu jednego „wadliwego" drzewa.

max_depth mówi o tym, jak szczegółowo model patrzy na dane. Im głębsze drzewo, tym więcej subtelnych zależności potrafi uchwycić, jednak zbyt duża głębokość sprawia, że model zapamiętuje dane zamiast się ich uczyć.

W modelu regresyjnym
n_estimators poprawia dokładność przewidywanej wartości liczbowej poprzez uśrednianie predykcji wielu drzew.

max_depth decyduje o tym, jak szczegółowo model odwzorowuje zależność między cechami kredytobiorcy a wysokością oprocentowania

Ocena Modeli klasyfikacyjnych:

W przypadku modelu klasyfikacyjnego zmienną, którą staramy się przewidzieć jest informacja czy kredyt został spłacony (wartość 0), czy też nie (wartość 1). Biorąc pod

uwagę specyfikę branży oraz rozkład przewidywanych danych, aby zniwelować ryzyko błędnego przypisania kategorii loan_status wartości 1 skupimy się na skuteczności przewidywania przez model wartości 1 gdy dane faktycznie miały taką wartość. Danych z wartością 1 w zbiorze jest znacznie mniej, co może prowadzić do błędnego szacowania.

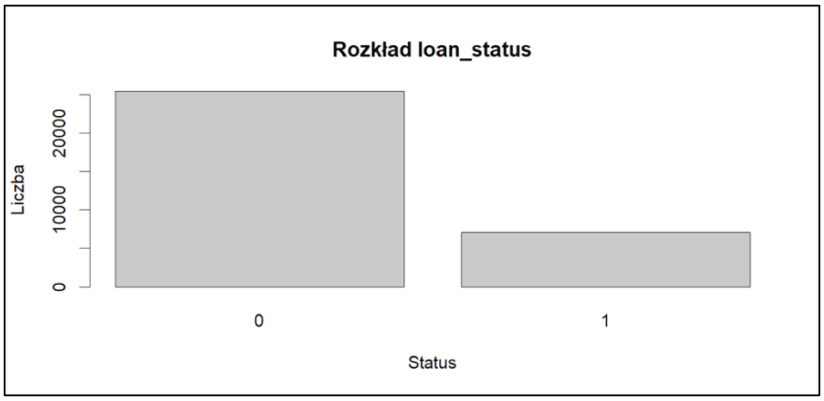

Wyniki przeprowadzonych testów porównawczych:

Model	Parametr	Accuracy	Recall
Decision Tree	max_depth=None	0,8939	0,7642
Decision Tree	min_samples_leaf=1	0,8939	0,7642
Decision Tree	min_samples_leaf=5	0,9161	0,7427
Random Forest	n_estimators=200	0,9337	0,7241
Random Forest	n_estimators=100	0,9329	0,7231
Random Forest	max_depth=None	0,9329	0,7231
Random Forest	n_estimators=50	0,9335	0,7222
Decision Tree	max_depth=10	0,9323	0,7065
Random Forest	n_estimators=10	0,9286	0,7061
Decision Tree	min_samples_leaf=20	0,9259	0,7051
SVM	C=100.0	0,9129	0,6875
Random Forest	max_depth=10	0,9276	0,6812
Decision Tree	min_samples_leaf=50	0,922	0,6763
SVM	C=10.0	0,9188	0,6743
SVM	C=1.0	0,9166	0,6577
SVM	kernel=rbf	0,9166	0,6577
SVM	kernel=poly	0,9068	0,6284
Decision Tree	max_depth=5	0,9095	0,6196

KNN	n_neighbors=3	0,879	0,5908
KNN	metric=manhattan	0,8884	0,5791
KNN	n_neighbors=5	0,8847	0,5737
KNN	metric=euclidean	0,8847	0,5737
KNN	metric=minkowski	0,8847	0,5737
KNN	n_neighbors=7	0,8874	0,5674
SVM	kernel=linear	0,8702	0,5605
KNN	n_neighbors=9	0,8875	0,5547
SVM	C=0.1	0,8924	0,5439
KNN	metric=chebyshev	0,8746	0,5386
Decision Tree	max_depth=3	0,8835	0,5264
Random Forest	max_depth=5	0,8927	0,5083
SVM	kernel=sigmoid	0,7319	0,3872
Random Forest	max_depth=3	0,8583	0,3428

Najlepszą skutecznością ogólną (93,37% Accuracy) wykazał się Random Forest z 200 drzewami. Algorytmy zespołowe najlepiej radzą sobie z klasyfikacją. Najwyższy Recall osiągnęło Drzewo Decyzyjne bez ograniczenia głębokości (76,42%), choć przy ryzyku przetrenowania. Najlepszym kompromisem okazało się Drzewo z `min_samples_leaf=5` ,Accuracy 91,61% przy Recall 74,27%.

Drzewa i Lasy Losowe wyraźnie przewyższają KNN i SVM, co wynika z nieliniowego i "drzewiastego" charakteru danych kredytowych. KNN osiągnął Recall jedynie 53–59%, co w kontekście bankowym oznacza pominięcie niemal połowy dłużników. SVM z jądrem sigmoidalnym (38,7% Recall) całkowicie dyskwalifikuje się w tym zastosowaniu.

Ocena modeli regresyjnych:

W przypadku modelu regresyjnego zmienną, którą staramy się przewidzieć, jest wartość oprocentowania kredytu (loan_int_rate). Jest to zmienna wyrażona w procentach, która w analizowanym zbiorze przyjmuje wartości z zakresu 6–20%. W projekcie analizowano wpływ różnych parametrów czterech wybranych metod (KNN, SVR, drzewo decyzyjne, las losowy) na skuteczność przewidywania oprocentowania.

Do oceny jakości modeli wykorzystujemy trzy miary: RMSE (pierwiastek błędu średniokwadratowego, MAE (średni błąd bezwzględny) oraz współczynnik determinacji

R^2. Dodatkowo porównanie wyników na zbiorze uczącym i testowym pozwala ocenić, czy model nie jest przetrenowany.

model	parametr	wartosc	RMSE_train	RMSE_test	MAE_train	MAE_test	R2_train	R2_test
KNN	n_neighbors	3	1,34	1,97	0,92	1,34	0,81	0,59
KNN	n_neighbors	5	1,54	1,94	1,05	1,32	0,75	0,60
KNN	n_neighbors	7	1,65	1,94	1,12	1,31	0,71	0,60
KNN	n_neighbors	9	1,73	1,95	1,17	1,32	0,68	0,59
KNN	metric	euclidean	1,54	1,94	1,05	1,32	0,75	0,60
KNN	metric	manhattan	1,54	1,93	1,06	1,32	0,75	0,60
KNN	metric	chebyshev	1,56	1,95	1,07	1,35	0,74	0,60
KNN	metric	minkowski	1,54	1,94	1,05	1,32	0,75	0,60
SVR	C	0.1	1,74	1,72	1,21	1,21	0,68	0,68
SVR	C	1.0	1,39	1,43	0,96	1,01	0,80	0,78
SVR	C	10.0	1,22	1,37	0,83	0,98	0,84	0,80
SVR	C	100.0	1,12	1,45	0,73	1,05	0,87	0,78
SVR	kernel	linear	1,31	1,32	0,93	0,94	0,82	0,81
SVR	kernel	poly	1,61	1,70	1,15	1,21	0,73	0,69
SVR	kernel	rbf	1,39	1,43	0,96	1,01	0,80	0,78
Decision Tree	max_depth	3	2,16	2,15	1,67	1,66	0,51	0,51
Decision Tree	max_depth	5	1,49	1,47	0,99	0,99	0,76	0,77
Decision Tree	max_depth	10	1,22	1,36	0,88	0,97	0,84	0,80
Decision Tree	max_depth	None	0,02	1,85	0,00	1,34	1,00	0,64
Decision Tree	min_samples_leaf	1	0,02	1,85	0,00	1,34	1,00	0,64
Decision Tree	min_samples_leaf	5	0,95	1,54	0,70	1,15	0,91	0,75
Decision Tree	min_samples_leaf	20	1,20	1,37	0,89	1,02	0,85	0,80
Decision Tree	min_samples_leaf	50	1,30	1,37	0,93	0,99	0,82	0,80

Random Forest	n_estimators	10	0,59	1,38	0,40	1,02	0,96	0,80
Random Forest	n_estimators	50	0,50	1,32	0,36	0,97	0,97	0,81
Random Forest	n_estimators	100	0,49	1,32	0,36	0,96	0,97	0,82
Random Forest	n_estimators	200	0,49	1,31	0,35	0,96	0,97	0,82
Random Forest	max_depth	3	2,16	2,15	1,67	1,66	0,51	0,51
Random Forest	max_depth	5	1,49	1,46	0,99	0,99	0,76	0,77
Random Forest	max_depth	10	1,20	1,31	0,88	0,94	0,85	0,82
Random Forest	max_depth	None	0,49	1,32	0,36	0,96	0,97	0,82

Analiza wyników

Najlepsze rezultaty na zbiorze testowym uzyskał Las Losowy z ograniczoną głębokością drzew (max_depth=10), osiągnął RMSE równe 1,31 p.p., MAE 0,94 p.p. oraz R^2 na poziomie 0,82. Oznacza to, że model wyjaśnia około 82% zmienności oprocentowania, a typowa pomyłka w prognozie stopy procentowej wynosi poniżej jednego punktu procentowego. Bardzo zbliżony wynik (RMSE =1,31 R^2= 0,82) dało zwiększenie liczby drzew do 200, co potwierdza, że metody zespołowe najlepiej radzą sobie z tak zróżnicowanymi danymi.

Warto zwrócić uwagę na wyraźną różnicę pomiędzy wynikami na zbiorze uczącym a testowym w przypadku drzewa decyzyjnego bez ograniczenia głębokości (max_depth=None). Model osiągnął RMSE na zbiorze uczącym równe 0,02 p.p. oraz R^2 równe 1,00, podczas gdy na zbiorze testowym RMSE wzrosło do 1,85 p.p., a R^2 spadło

do 0,64. Jest to klsyczny przykład przetrenowania, drzewo zapamiętało obserwacje uczące zamiast nauczyć się ogólnych zależności.

Metoda SVR okazała się konkurencyjna wobec lasu losowego, ale wyłącznie przy odpowiednim doborze parametrów. Wariant z jądrem liniowym dał RMSE testowe:1,32 p.p. oraz R^2 = 0,81, co wskazuje, że zależność między cechami a oprocentowaniem ma w dużej mierze charakter liniowy nieliniowe jądra radzą sobie gorzej jądro RBF: RMSE 1,43; poly: RMSE 1,70). Parametr C również wpływał na wyniki w przewidywalny sposób: przy C=0,1 model był zbyt „uproszczony" RMSE : 1,72, zwiększenie do C=10 poprawiło wynik do 1,37, natomiast dalsze zwiększanie do C=100 pogorszyło RMSE testowy =1,45przy jednoczesnej poprawie Rmse uczącego : 1,12; to kolejny sygnał przetrenowania.

Algorytm KNN wypadł najsłabiej w tym porównaniu. niezależnie od liczby sąsiadów 3–9 i zastosowanej metryki euklidesowej manhattańskiej, czybyszewskiego, minkowskiego , RMSE utrzymywało się w przedziale 1,93–1,97 p.p. , a R^2 nie przekroczyło 0,60. Oznacza to, że dla tego zbioru danych metoda oparta na odległościach nie potrafi oddać zależności prowadzących do ustalenia oprocentowania.

Najsłabsze konfiguracje to drzewo decyzyjne oraz las losowy z max_depth=3, oba osiągnęły RMSE równe 2,15 p.p. i R^2 zaledwie 0,51, co pokazuje, że przy tak silnym ograniczeniu głębokości model jest niedouczony i nie jest w stanie uchwycić struktury danych.

Wnioski

W zadaniu przewidywania oprocentowania kredytu najlepiej sprawdziły się metody oparte na drzewach decyzyjnych w wariancie zespołowym, czyli las losowy, pod warunkiem kontrolowania głębokości drzew. Podobną skuteczność osiągnęła regresja SVR z jądrem liniowym, co sugeruje, że zależność między cechami a oprocentowaniem da się w dużej mierze opisać funkcją liniową. Najgorzej poradził sobie KNN — metoda oparta na odległościach źle radzi sobie w sytuacji, gdy znaczna część cech to zakodowane zero-jedynkowo zmienne jakościowe.

Porównanie wyników na zbiorze uczącym i testowym potwierdza praktyczną zasadę: modele o największej elastyczności (drzewo bez ograniczeń, SVR z wysokim parametrem C) osiągają najdopasowanie na danych uczących, ale gorzej generalizują.

Najlepszy balans między jakością predykcji na zbiorze uczącym a skutecznością na danych testowych osiągnął Las Losowy z parametrem max_depth=10. To rozwiązanie warto uznać za docelowe, gdyż średnia pomyłka w prognozie oprocentowania nie przekracza jednego punktu procentowego, co w realiach sektora finansowego jest wynikiem satysfakcjonującym.

Literatura

https://home.agh.edu.pl/~horzyk/lectures/miw/SI-MIW-KNN+AGDS.pdfhttps://agathos.sgh.waw.pl/spisy/pelny_tekst/d88348.pdf
https://winntbg.bg.agh.edu.pl/skrypty4/0599/podstawy_uczenia.pdf